

Calibracao do Raciocinio Cientifico Automatico via Problemas da Olimpiada Internacional de Matematica: Arquitetura, Evolucao e Licoes do Ecossistema OpenCode v4.3

Ecossistema OpenCode — AutoEvolve v4.3¹

^aPPGTE/CT/UFC — Universidade Federal do Ceara, Fortaleza, CE, Brasil

Abstract

Este artigo apresenta a arquitetura, evolucao e licoes aprendidas no desenvolvimento do ecossistema OpenCode v4.3 — uma plataforma multiagente para raciocinio cientifico automatico calibrada exclusivamente por problemas da Olimpiada Internacional de Matematica (IMO). O percurso documentado abrange seis estagios de maturidade, iniciando-se com a constatacao de que verificadores simbolicos (V1-V6) sao insuficientes para garantir correcao matematica (Estagio 0, IMO 2025 P1) e culminando com um motor de elegancia autonoma dotado de calibracao multidimensional em 15 criterios, capaz de elevar solucoes de nota C (63/100) para A+ (97/100) em tres iteracoes automaticas (Estagio 5).

A arquitetura final integra 38 agentes especializados em pipeline de 7 fases, verificacao simbolica deterministica (Cora-Debate), verificacao estrutural de provas com grafo de dependencias (LemmaGraph/P20), taxonomia de 200 raciocinios em 24 categorias fundamentada em 150 referencias academicas, teoria dos jogos computacional (Nash, Minimax, Shapley), integracao de sistemas complexos (CORA Integration), e um ciclo de auto-melhoria baseado em calibracao multidimensional.

A contribuicao central deste trabalho e a demonstracao empirica de que problemas de olimpiada constituem o banco de provas ideal para calibrar sistemas de raciocinio artificial: suas respostas discretas e verificaveis expoem tanto as limitacoes fundamentais quanto os caminhos de superacao. A trajetoria do Proof Confidence Index (PCI) — de 85/100 (falso positivo) para 30/100 (deteccao de erro) para 88/100 (solucao correta) — demonstra que o sistema aprendeu a reconhecer seus proprios erros antes de produzir respostas corretas.

Keywords: Raciocinio cientifico automatico, Sistemas multiagente, Olimpiada Internacional de Matematica, Verificacao de provas, Calibracao multidimensional, Taxonomia de raciocinios, Elegancia matematica, Prova estrutural, Auto-melhoria autonoma

Calibracao do Raciocinio Cientifico Automatico via Problemas da Olimpiada Internacional de Matematica: Arquitetura, Evolucao e Licoes do Ecosystema OpenCode v4.3

Ecosystema OpenCode — AutoEvolve v4.3¹

^bPPGTE/CT/UFC — Universidade Federal do Ceara, Fortaleza, CE, Brasil

Sumário

1. Introducao: A Genese do Problema

1.1. O Contexto

O ecosystema OpenCode [?] emergiu como uma infraestrutura de agentes de inteligencia artificial integrando mais de 600 componentes: 125 agentes catalogados (3–7 ativos por sessao, ativacao sob demanda), 41 servidores MCP (Model Context Protocol), 106 skills em 13 categorias, e aproximadamente 120.000 linhas de codigo Python. Ate a versao 4.2, o sistema contava com 18 pilares arquiteturais (P1–P18), abrangendo desde busca semantica ate auditoria academica com teoria dos jogos [?].

O modulo Cora-Debate (P19) [?] foi projetado para suprir uma lacuna identificada: a verificacao simbolica formal de afirmacoes geradas por Large Language Models (LLMs). Inspirado pelo framework MAD (Multi-Agent Debate) [?] e pelo paradigma de self-consistency [?], o Cora-Debate implementa 6 verificadores simbolicos independentes (V1–V6: dimensional, algebrico, contraexemplos, estatistico, numerico, PDE) que operam fora do espaco latente do LLM, utilizando SymPy [?], SciPy [?], e mecanismos deterministicos.

1.2. O Incidente IMO 2025

O Problema 1 da IMO 2025 [?] define uma reta no plano como *ensolarada* (*sunny*) se nao e paralela ao eixo x , ao eixo y , nem a reta $x + y = 0$. Para $n \geq 3$, pergunta-se: quais valores de k (numero de retas ensolaradas entre n retas) permitem cobrir todos os pontos (a, b) com $a, b \geq 1$ e $a + b \leq n + 1$?

A resposta correta e $k \in \{0, 1, 3\}$ para todo $n \geq 3$, conforme confirmado independentemente por Evan Chen [?] e Google DeepMind [?]. A resposta e **constante** — nao cresce com n — porque o problema admite uma reducao estrutural (R13): para $n \geq 4$, qualquer cobertura valida

contem uma das tres “retas longas de borda” ($y = 1, x = 1$ ou $x + y = n + 1$), todas nao-ensolaradas. Removendo esta reta, o problema reduz-se de n para $n - 1$ preservando k . Por inducao, k deve ser viavel para $n = 3$, onde a analise exhaustiva produz $k \in \{0, 1, 3\}$.

O sistema OpenCode, operando apenas com os verificadores V1-V6, produziu a resposta $k \in \{0, 1, \dots, \lfloor (2n - 1)/3 \rfloor\}$ com alta confianca (PCI estimado em 85/100). Esta resposta e **matematicamente falsa**: para $n = 4$, o sistema declara $k = 2$ como valor possivel, mas a verificacao manual demonstra que $k = 2$ e impossivel — as duas retas ensolaradas nao conseguem cobrir os tres pontos restantes apos remover as retas de borda.

1.3. A Licao Fundamental

Este episodio cristalizou a licao que motiva todo o presente trabalho:

Licao Fundamental: Em problemas de ciencias exatas, basta um unico lema falso para invalidar toda a cadeia dedutiva. Sistemas de verificacao que checam apenas a *consistencia algebrica* de formulas (V1-V6) sao intrinsecamente insuficientes para garantir a *validade logica* de demonstracoes. E necessario construir uma camada adicional que inspecione a *estrutura da prova* — suas dependencias, seus invariantes, seus casos base, e sua conformidade com fontes externas independentes.

Generalizacao: Testar a correcao em outros problemas da IMO para verificar se a melhoria e geral ou especifica.

1.4. Objetivos e Contribuicoes

Este artigo documenta a evolucao arquitetonica completa decorrente desta licao. Os objetivos especificos sao:

- (i) Catalogar as cinco falhas sistematicas que o sistema apresentou ao resolver o IMO 2025 P1, estabelecendo uma taxonomia de fragilidades;
- (ii) Descrever a construcao incremental de quatro novas camadas de verificacao (P20-P23), cada uma enderecando uma falha especifica;
- (iii) Apresentar a expansao da taxonomia de raciocinios de 6 para 200 tipos em 24 categorias, fundamentada em 150 referencias academicas;
- (iv) Documentar a arquitetura de ativacao dos 38 agentes implementados no pipeline de 7 fases do ReasoningOrchestrator v11;
- (v) Demonstrar o ciclo de auto-melhoria baseado em calibracao multidimensional (15 criterios), que eleva solucoes de nota C para A+.

2. Metodologia: Abordagem Empirica Iterativa

2.1. Falsificacionismo como Motor de Desenvolvimento

O desenvolvimento seguiu uma metodologia de **calibracao por falha** inspirada no falsificacionismo de Popper [?] e na teoria de revolucoes cientificas de Kuhn [?]. O ciclo fundamental e:

- (1) **Exposicao:** Submeter o sistema a um problema da IMO com resposta conhecida e independentemente verificada.
- (2) **Diagnostico:** Se o sistema falha, identificar *qual* componente da arquitetura e responsavel pela falha.
- (3) **Correcao:** Projetar e implementar uma nova camada arquitetonica que mitiga a falha identificada.
- (4) **Verificacao:** Submeter novamente o sistema ao mesmo problema e confirmar que a falha nao se repete.

- (5) **Generalizacao:** Testar a correcao em outros problemas da IMO para verificar se a melhoria e geral ou especifica.

2.2. Seis Estagios de Maturidade

A Tabela ?? resume a trajetoria completa.

Tabela 1: Estagios de maturidade do ecossistema OpenCode

Est.	Nome	Falha Exposta	Solucao Construida
0	Fragilidade Inicial	IMO 2025 P1: resposta falsa com PCI 85/100	Diagnostico de 5 maticas
1	Cora-Debate	Formulas verificadas, provas nao	6 verificadores sintaticos (V1-V6) + Q-Score Unificado
2	Verif. Estrutural	LemmaGraph vazio, sem cross-ref, sem caso base	P20-P23: grafo de dependencias + CrossRef + CaseBase + InductiveReasoning
3	Taxonomia	Apenas 4/14 raciocinios da IMO implementados	200 raciocinios e 24 categorias, 150 referencias academicas
4	Orquestracao	Agentes isolados, sem pipeline coordenado	38 agentes em 7 fases: ReasoningOrchestrator v11 + Theory + CORA
5	Elegancia Autonoma	Solucoes corretas mas ineficientes (C, 63/100)	Busca ativa de melhorias + Calibracao 15-Dimensional + Auto-melhoria

3. Estagio 0: Diagnostico da Fragilidade Inicial

3.1. Contextualizacao do IMO 2025 — Problema 1

3.1.1. Enunciado Formal

Seja $n \geq 3$ um inteiro. Uma reta no plano e *ensolarada* se nao e paralela ao eixo x , ao eixo y , nem a reta $x + y = 0$. Determine todos os inteiros nao-negativos k para os quais existem n retas distintas tais que:

- (i) Para todos $a, b \in \mathbb{N}^*$ com $a + b \leq n + 1$, o ponto (a, b) pertence a pelo menos uma das n retas;
- (ii) Exatamente k das n retas sao ensolaradas.

3.1.2. Solucao Correta

A resposta e $k \in \{0, 1, 3\}$ para todo $n \geq 3$. A demonstracao [?] utiliza o **Teorema da Reta Longa de Borda**: para $n \geq 4$, qualquer cobertura valida contem uma das tres retas $y = 1$, $x = 1$, ou $x + y = n + 1$ — todas nao-ensolaradas. A remocao desta reta reduz n a $n - 1$ preservando k . Por inducao, k deve ser viavel para o caso base $n = 3$, cuja analise exhaustiva fornece $k \in \{0, 1, 3\}$.

A demonstracao mobiliza 11 raciocinios distintos: R13 (Reducao Estrutural), R14 (Invariante), R08 (Dedutivo-Natural), R04 (Tradutivo), R10 (Modular), R15 (Caso-Base), R22 (Contraexemplo), R26 (Teste-de-Estresse), R17 (Construtivo-Explicito), R19 (Enumerativo), e R11 (Encadeamento-Reverso).

3.2. As Cinco Falhas Sistematicas

Uma auditoria externa independente [?] identificou cinco falhas que, coletivamente, explicam por que o sistema nao detectou seu proprio erro. A Tabela ?? as documenta com precisao.

Tabela 2: Cinco falhas sistematicas detectadas — IMO 2025 Problema 1

#	Nome	Manifestacao	Causa Raiz
F1	Claim Nao-Justificada	“Argumento de pigeonhole generalizado” enunciado sem demonstracao	LemmaGraph sem rastreamento de dependencias mas
F2	Construcao Quebrada	$m_j = -1 - 1/j$ falha para $n = 4, k = 2$: ponto $(2, 3)$ nao coberto	V3 testou o li nao a $constru$
F3	Erro de Indice	$k + 1$ vs k anti-diagonais restantes na contagem	V2 (SymPy) v a formula as nao sua $deriv$
F4	Contradicao Interna	$ p + q = 1 \Rightarrow m \in \{0, \infty\}$ vs $m = -2$ com $ p + q = 1$	Nenhum dete contradicao a sistema
F5	Cross-Ref Ausente	Resposta $k \in \{0, 1, \dots, \lfloor (2n - 1)/3 \rfloor\}$ conflita com Evan Chen e DeepMind	P23 (CrossRe tor) nao im tado

3.3. Mapeamento Falha → Solucao

Cada falha identificada tornou-se o requisito para um novo pilar arquitetonico. A Tabela ?? (apresentada em paisagem na pagina seguinte) documenta este mapeamento com precisao.

Tabela 3: Mapeamento: falha → pilar → raciocinio → implementacao

#	Falha	Pilar	Funcao	Raciocinio	Arquivo/Modulo
F1	Claim Nao-Justificada: “pigeonhole generalizado” sem demonstracao	P20 (Lemma-Graph)	Grafo de dependencias entre lemas. Propagacao de falha via BFS. Ordenacao topologica. Deteccao de ciclos.	R31 (Dependencia Logica)	refined_agents.py (RefinedLemmaTracker)
F2	Construcao Quebrada: $m_j = -1 - 1/j$ falha para $n = 4, k = 2$; ponto $(2, 3)$ descoberto	P22 (Exhaustive-BaseChecker)	Enumeracao exhaustiva para $n \leq 5$. Verdade computacional independente de prova humana.	R26 (Teste de Estresse), R27 (Exhaustao Computacional)	critical_agents.py (ExhaustiveAgent, StressTestAgent)
F3	Erro de Indice: $k+1$ vs k anti-diagonais restantes na contagem dos pontos	P21 (InductionVerifier)	Verificacao de reducao/inducao. Checa preservacao de invariante e validade do caso base.	R08 (Dedutivo-Natural), R12 (Inducao Matematica)	final_agents.py (InductionAgent)
F4	Contradicao Interna: $ p + q = 1 \Rightarrow m \in \{0, \infty\}$ vs $m = -2$ com $ p + q = 1$	V2-V3 Refinados	Deteccao de contradicao algebrica (SymPy) e textual. Verificacao de consistencia cruzada entre lemas.	R24 (Contradicao Interna), R22 (Contraexemplo)	refined_agents.py (RefinedContradictionAgent)
F5	Cross-Ref Ausente: resposta $k \in \{0, 1, \dots, \lfloor (2n - 1)/3 \rfloor\}$ conflita com Evan Chen e DeepMind	P23 (CrossRefValidator)	Comparacao automatica com fontes externas independentes. Alerta de conflito antes da validacao.	R28 (Cross-Reference)	critical_agents.py (CrossRefAgent)

4. Estagios 1–3: Construção da Infraestrutura

4.1. Estagio 1 — Cora-Debate V1-V6

O módulo Cora-Debate (P19) implementa 6 verificadores simbólicos que operam via protocolo MCP (Model Context Protocol) sobre stdio JSON-RPC. Cada verificador é determinístico e independente do LLM, fornecendo uma camada de verificação externa ao espaço latente do modelo.

Tabela 4: Verificadores Cora-Debate V1-V6 — Capacidades e Limitações

ID	Verificador	Motor Computacional	Limitação Conhecida
V1	Análise Dimensional	Ontologia de 24 unidades (MLT)	Não detecta fatores constantes errados (ex: $F = 2ma$ passaria)
V2	Verif. Algebrico	SymPy	Apenas identidades lineares
V3	Contraexemplos	Busca randomizada em $[-100, 100]$	Não prova afirmações verdadeiras; domínio finito
V4	Estatístico	SciPy: Shapiro-Wilk, Pearson r	Requer $n \geq 3$ amostras; não implementa não-paramétricos
V5	Númerico	Erro absoluto/relativo $< 10^{-6}$	Não detecta cancelamento catastrófico
V6	PDE/EDO	SymPy	Apenas EDOs lineares; complexidade $O(L \cdot 2^n)$

O Cora-Debate integra também um motor de seleção adaptativa de debatedores via algoritmo UCB1 [?] (Q-Score), calibração de confiança via Platt Scaling [? ?], e self-consistency $K = 7$ com votação ponderada. A validação funcional alcançou 38/38 testes (100% aprovação).

Limitação fundamental: Conforme demonstrado pelo IMO 2025 P1, os verificadores V1-V6 inspecionam a *consistência algebrica* das fórmulas, mas não a *validade lógica* da cadeia dedutiva que as conecta. Eles verificam se as peças se encaixam, mas não se o edifício tem alicerces.

4.2. Estagio 2 — Verificação Estrutural de Provas (P20-P23)

Para suprir esta lacuna, quatro novos pilares foram projetados e implementados [?], cada um endereçando uma falha específica da Tabela ??.

4.2.1. P20 — LemmaGraph

O LemmaGraph implementa um grafo direcionado de dependências entre lemas utilizando NetworkX. Cada

lema e um nó; cada dependência (“Lema 2 usa Lema 1”) e uma aresta direcionada. As operações fundamentais são:

- **Ordenação topológica:** Determina a ordem correta de demonstração (pre-requisitos primeiro).
- **Profundidade:** O caminho mais longo no DAG revela a complexidade da prova (número máximo de lemas encadeados).
- **Deteção de ciclos:** Identifica dependências circulares que invalidam a estrutura lógica.

- **Propagação de falha:** Se um lema é invalidado, uma busca em largura (BFS) propaga a falha para todos os seus descendentes no grafo.

No IMO 2025 P1, o LemmaGraph teria detectado que o “pigeonhole generalizado” (F1) era um nó-folha sem demonstração — uma dependência quebrada que invalidaria automaticamente o Teorema Final.

4.2.2. P21 — InductionVerifier
O InductionVerifier verifica a validade de reduções e induções, inspirado pelo princípio de indução estrutural de Burstall [?] e pela lógica de Hoare [?]. O verificador checa:

- Preservação do invariante:** A quantidade k não se altera quando a reta de borda é removida ($n \rightarrow n-1$)?
- Caso base:** O menor n (tipicamente $n = 3$) foi verificado exaustivamente?
- Passo indutivo:** A implicação $P(n-1) \Rightarrow P(n)$ é válida para todos os n no domínio?

4.2.3. P22 — ExhaustiveBaseChecker

Para $n \leq 5$, o ExhaustiveBaseChecker enumera todas as configurações possíveis de retas, fornecendo uma **verdade computacional** independente de qualquer prova humana [?]. Para o IMO 2025 P1 com $n = 3$, a busca exaustiva confirma $k \in \{0, 1, 3\}$ como os únicos valores viáveis — um resultado que teria refutado imediatamente a resposta $k \in \{0, 1, 2, \dots\}$ do sistema original.

4.2.4. P23 — CrossRefValidator

O CrossRefValidator compara a resposta do sistema com fontes externas independentes. As fontes configuradas incluem: Evan Chen (IMO Solution Notes) [?], Google DeepMind (IMO Solutions) [?], e Art of Problem Solving (AoPS). Se a resposta do sistema divergir de *todas* as fontes externas, um alerta de conflito é emitido e o PCI é penalizado.

4.3. Proof Confidence Index (PCI)

O PCI integra as quatro camadas em uma métrica unificada de 0–100:

$$PCI = 30\% \cdot P23 + 25\% \cdot P22 + 25\% \cdot P20 + 10\% \cdot P21 + 10\% \cdot (V1-V6) \tag{1}$$

Os pesos refletem a importância relativa de cada camada: cross-reference (30%) e a camada mais crítica porque fornece validação externa independente; caso base exaustivo (25%) fornece verdade computacional; grafo de lemas (25%) garante integridade estrutural.

4.4. Estágio 3 — Taxonomia de 200 Raciocínios

A análise de 7 problemas da IMO (2024-2025) revelou que as soluções oficiais mobilizam 14 raciocínios distintos. Destes, apenas 4 estavam implementados no ecossistema original (R08, R10, R17, R22). Esta constatação desencadeou a construção de uma taxonomia abrangente [?], expandida em três ondas sucessivas.

Tabela 5: Expansão da taxonomia de raciocínios em três ondas

Onda	Escopo	Tipos	Novas
1	Raciocínio matemático-olímpico	34 (R01-R34)	I-VII: Indutiva, Dedutiva, Combinatória, Geométrica, Algébrica, Cognitiva
2	Dominios expandidos	68 (R01-R68)	VIII-X: Experimental, Argumentativo, Decisivo, Otimizatório, Conceitual
3	Cobertura universal	200 (R01-R200)	XIII-XV: Avançada, Estocástica, Evolutiva, Controlada, Segura, Socio-Ambiental

Cada raciocínio é fundamentado em uma referência acadêmica primária com DOI, ISBN ou arXiv verificável. A Tabela ?? apresenta o núcleo universal — os 10 raciocínios que aparecem em pelo menos 3 dos 7 problemas IMO analisados.

Tabela 6: Nucleo universal de raciocinio olimpico (10 tipos, $\geq 3/7$ problemas)

ID	Raciocinio	Freq.	Exemplo de Uso
R10	Modular	7/7	Decompor em necessidade + suficiencia
R14	Invariante	7/7	$d_i \cdot d_{k+1-i} = n$ (simetria de divisores)
R19	Enumerativo	6/7	Enumerar $k \in \{0, 1, 3\}$ apos eliminar impossiveis
R22	Contraexemplo	6/7	$n = 4, k = 2$: construcao falha
R04	Tradutivo	5/7	$T(a, b) = (a - N_V, b - N_H)$ (bijecao)
R08	Dedutivo-Natural	5/7	$n + 1 - a \leq n - N_V \Rightarrow a \geq N_V + 1$
R15	Caso-Base	4/7	$n = 3$: analise exaustiva
R26	Teste-de-Estresse	4/7	Convex hull boundary: $3k - 3 \leq 2k$
R17	Construtivo-Explicito	4/7	$y = x, 2x + y = 5, x + 2y = 5$
R13	Redutivo-Estrutural	1/7	Reduzir $n \rightarrow n - 1$ preservando k

Tabela 7: Arquitetura de ativacao dos agentes — Pipeline de 7 fases

Fase	Funcao	Agentes	Dependencias
1	Fundacional	Notation, Abstraction, Modular	Nenhuma
2	Indutiva/Redutiva	Inductor, BaseCase, Induction	Abstracao
3	Dedutiva	LemmaTracker, DeductiveChain, BackwardChain, Quantificational	seAgentes
4	Construtiva	Constructor, StressTest	Lemmas
5	Refutacional	Contradiction, Contraexemplo, Reductio	prior
6	Verificacional	Exhaustive, CrossRef, Enumeration	Abstracao
7	Meta-Cognitiva	Generalization, ProofHealth (PCI)	seAgentes

Agentes cujas dependencias tem confianca < 0.3 sao automaticamente desativados. O LemmaGraph (P20) propaga falhas: se um agente essencial falha, todos os agentes que dependem dele sao marcados como nao-confiaveis.

5. Estagios 4–5: Orquestracao e Elegancia Autonoma

5.1. ReasoningOrchestrator v11

O orquestrador coordena 38 agentes em um pipeline sequencial de 7 fases. Cada agente declara explicitamente suas dependencias via metodo `get_dependencies()`, e o orquestrador resolve o grafo antes da execucao.

5.2. Teoria dos Jogos Computacional

Cinco agentes de teoria dos jogos foram implementados com motores computacionais puros (sem dependencia de LLM), baseados em [? ? ? ?]:

- **NashEquilibriumAgent:** Equilibrios puros ($O(n^2)$ por forza bruta) e mistos (formula analitica para matrizes 2×2).
- **MinimaxAgent:** Jogos de soma zero resolvidos via fictitious play iterativo (1000 iteracoes).
- **BackwardInductionAgent:** Equilibrio perfeito em subjogos via recursao na arvore do jogo.
- **ShapleyValueAgent:** Valor de Shapley exato por enumeracao de coalicoes ($O(n! \cdot 2^n)$).
- **EvolutionaryGameAgent:** Dinamica de replicadores para deteccao de Estrategias Evolutivamente Estaveis (ESS).

Testes em cenarios classicos confirmaram a precisao dos agentes: Dilema do Prisoneiro $\rightarrow$ (Defect, Defect); Matching Pennies $\rightarrow$ valor ≈ 0 ; Jogo da Maioria $\rightarrow$ Shapley $1/3$ para cada jogador.

5.3. CORA Integration — Sistemas Complexos

Inspirado pelo minicurso de Macedo (2025) [?] sobre Collaborative Reasoning Agents, o modulo CORA incorpora analogias da fisica de sistemas complexos ao debate multiagente:

- **ConsensusEngine:** Metrica de consenso C_r (Jacard pairwise) e oscilacao O_r (mudanca entre rodadas), com deteccao de fase (fragmentado → debatendo → convergindo → consenso).
- **OscillatorModel:** Agentes como osciladores acoplados com equacao $\frac{d^2 x_i}{dt^2} + \omega_i^2 x_i = \sum_{j \neq i} K_{ij}(x_j - x_i)$. Parametro de ordem de Kuramoto para deteccao de sincronizacao.
- **TemperatureController:** Temperatura por agente com annealing $T_i(t) = T_0 \cdot \alpha^t$ e ajuste adaptativo: aumentar T na fase fragmentada (exploracao), diminuir na fase convergente (precisao).
- **BellmanEngine:** Q-learning [? ?] com 6 acoes (speak, listen, challenge, agree, refine, propose) para otimizacao de estrategias de debate.

5.4. Elegancia Autonoma e Calibracao 15-D

5.4.1. Active Invariant Searcher

Diferentemente do InvariantAgent original (que fazia pattern-matching passivo), o novo motor implementa **5 estrategias de busca ativa** por invariantes matematicos: Simetria (pares complementares, dualidades), GCD/Coprimidade ($\gcd(p, p+1) = 1$), Algebrica (fatoracoes, series geometricas), Extremal (elementos maximos/minimos), e Recorrencia (padroes indutivos em cadeia).

Para o IMO 2002 P1 (“determine $n > 1$ composto tal que $d_i \mid d_{i+1} + d_{i+2}$ ”), o motor descobriu autonomamente 9 invariantes, incluindo os tres cruciais da solucao oficial: $d_i \cdot d_{k+1-i} = n$ (simetria de divisores, confianca 92%), $\gcd(p, p+1) = 1$ (coprimidade de consecutivos, confianca 88%), e a cascata indutiva $d_i = p^{i-1}$ (confianca 88%).

5.4.2. Solution Ranker

O ranking de solucoes utiliza 5 criterios de elegancia [? ?]: minimizacao de bifurcacoes (30%), riqueza de invariantes (25%), concisao da prova (20%), reusabilidade

das tecnicas (15%), e clareza estrutural (10%). Tecnicas como $\gcd(p, p+1) = 1$ pontuam 0.95 em reusabilidade, enquanto analise de casos pontua apenas 0.30.

5.4.3. Calibracao Avancada em 15 Dimensoes

O AdvancedCalibrationEngine expande os criterios para 15 dimensoes organizadas em 3 camadas ponderadas:

Tabela 8: Calibracao em 15 dimensoes — 3 camadas

Camada	Peso	Dimensoes	Exemplos
TIER 1 — Correcao	40%	D1-D4	Cross-Ref, Caso Contraexemplo, dimensional
TIER 2 — Elegancia	35%	D5-D9	Ramos, Invariante, Concisao, Produtividade, Simetria
TIER 3 — Valor Intelectual	25%	D10-D15	Reusabilidade, realizacao, Paradigma Historico, Compromisso, Educacional

O ciclo de auto-melhoria opera em tres iteracoes:

Iteracao 1: **Avaliar:** O CalibrationAgent avalia a solucao atual nas 15 dimensoes, produzindo um relatorio com nota (A+ a F), forcas, fraquezas, e recomendacoes.

Iteracao 2: **Aplicar:** O RecommendationEngine traduz as recomendacoes em acoes concretas (“buscar invariantes” → ativar ActiveInvariantSearcher; “eliminar bifurcacoes” → ativar $\gcd(p, p+1) = 1$).

Iteracao 3: **Verificar:** A solucao modificada e re-avaliada. Se o score aumentou, a modificacao e mantida. Caso contrario, e revertida.

Para o IMO 2002 P1, a trajetoria foi: 63/100 (C) → 74/100 (B) → 86/100 (A) → 97/100 (A+), com ganhos de +11, +12 e +11 pontos respectivamente. A Tabela ?? (em paisagem) detalha cada iteracao.

Tabela 9: Ciclo de auto-melhoria — IMO 2002 Problema 1 ($n = p^m$, $m \geq 2$)

Iter.	Melhoria Aplicada	Dimensoes Impactadas (ganhos)	Agentes Mobilizados	Paradigma	Score	Nota
0	Baseline: analise de casos ($q < p^2$ vs $p^2 < q$); 2 bifurcacoes; 8 passos	Nenhum invariante descoberto	R08 (Dedutivo), R19 (Enumerativo)	case_analysis	63	C
1	+1 invariante: $d_i \cdot d_{k+1-i} = n$ (simetria complementar de divisores)	D6 (+30pts): 0→30. D9 (+25pts): 0→25. D10 (+15pts): 30→45	ActiveInvariantSearcher (sime- tria), InvariantAgent	invariant_disco	74	B
2	$\gcd(p, p + 1) = 1$: elimina bifurcacao de casos + adiciona tecnica reutilizavel	D5 (+40pts): 60→100. D10 (+40pts): 45→85. D7 (+20pts): 50→70	ActiveInvariantSearcher (gcd), ContradictionAgent	symmetry_exploitation	86	A
3	Cascata indutiva $d_i = p^{i-1}$. Verificacao SymPy (V2). Alinhamento com solucao IMO oficial.	D7 (+20pts): 70→90. D12 (+60pts): 20→85. D14 (+60pts): 30→90. D13 (+50pts): 35→85	InductionAgent (R12), ExhaustiveAgent (V2), CrossRefAgent (P23), GeneralizationAgent (R34)	reduction + induction	97	A+

6. Resultados e Discussao

6.1. Trajetoria do PCI — A Metrica que Aprendeu a Duvidar

A Tabela ?? documenta a evolucao do Proof Confidence Index para o IMO 2025 P1 ao longo dos estagios. O fenomeno mais significativo e a **queda abrupta** entre os Estagios 1 e 2.

Tabela 10: Evolucao do PCI — IMO 2025 Problema 1

Est.	Estado do Sistema	PCI	Interpretacao	Nota
0	Apenas V1-V6 (verif. simbolica)	85	Falso positivo: sistema confiante em resposta errada	B
1	Cora-Debate completo (38 testes)	85	Idem — verificadores aprovam formulas, nao provas	B
2	+P20-P23 (CrossRef detecta conflito)	30	Erro detectado! Sistema reconhece a propria falha	F
3	+Taxonomia expandida (200 raciocinios)	45	Melhoria parcial — mais ferramentas, mas ainda sem solucao	D
4	+Orquestrador v11 + Game Theory + CORA	55	Pipeline funcional, cross-ref OK, LemmaGraph populado	C
5	+Elegancia autonoma + Calibracao 15-D	88	Solucao correta com invariantes e elegancia	A

A queda de 85 para 30 nao e uma regressao — e um **avanco**. Ela representa o momento em que o sistema adquiriu a capacidade de *reconhecer que estava errado*. O CrossRefAgent (P23) identificou que a resposta do sistema ($k \in \{0, 1, \dots, \lfloor (2n - 1)/3 \rfloor\}$) conflitava com as fontes externas ($k \in \{0, 1, 3\}$), e o LemmaGraph (P20) propagou a falha do “pigeonhole generalizado” nao-justificado para todos os lemas dependentes.

Este comportamento e precisamente o desejado: **um sistema de raciocinio confiavel deve saber quando esta errado antes de saber quando esta certo.**

6.2. Desempenho em 7 Problemas IMO

A Tabela ?? (em paisagem) apresenta o desempenho completo.

Tabela 11: Desempenho no Estagio 5 — 7 problemas IMO (2024-2025, 2002)

Problema	Ano	Resposta	Dominio	Correta?	Raciocinios-Chave Mobili- zados	PCI
IMO 2025 P1	2025	$k \in \{0, 1, 3\}$	Geom. Combinatoria	Sim	R13 (Reducao), R14 (Invari- ante), R15 (Caso-Base), R04 (Tradutivo)	88
IMO 2024 P1	2024	α par	Teoria dos Numeros	Sim	R10 (Modular), R12 (Indu- cao), R19 (Enumerativo)	82
IMO 2024 P2	2024	$(a, b) = (1, 1)$	Teoria dos Numeros	Sim	R14 (Invariante), R09 (Quantificacional), R23 (Reductio)	78
IMO 2024 P3	2024	Periodica	Combinatoria	Sim	R14 (Invariante), R26 (Teste- Estresse), R12 (Inducao)	75
IMO 2024 P6	2024	$c = 2$	Eq. Funcional	Sim	R14 (Invariante), R17 (Cons- trutivo), R04 (Tradutivo)	80
IMO 2002 P1	2002	$n = p^m, m \geq 2$	Teoria dos Numeros	Sim	R08 (Dedutivo), R19 (Enu- merativo), R22 (Contraexem- plo)	90
IMO 2002 P1 + Elegancia	2002	$n = p^m$ (via simetria)	Teoria dos Numeros	Sim + Elegante	R14 (Invariante), R12 (Indu- cao), R10 (Modular)	92

6.3. Comparacao Brute Force vs Elegante

A Tabela ?? quantifica a superioridade da abordagem elegante em 15 dimensoes para o IMO 2002 P1.

Tabela 12: Brute Force vs Elegante — 15 dimensoes (IMO 2002 P1)

Dimensao	Brute Force	Elegante	Δ
D1 — Cross-Reference	100	100	0
D2 — Caso Base	100	100	0
D3 — Contraexemplos	100	100	0
D4 — Dimensional	100	100	0
D5 — Minimizacao de Ramos	60	100	+40
D6 — Riqueza de Invariantes	0	90	+90
D7 — Concisao	50	90	+40
D8 — Profundidade	85	100	+15
D9 — Simetria	0	90	+90
D10 — Reusabilidade	30	90	+60
D11 — Generalizacao	20	70	+50
D12 — Paradigma	20	85	+65
D13 — Alinhamento Historico	35	85	+50
D14 — Verificabilidade	30	90	+60
D15 — Clareza Educacional	60	85	+25
Total Ponderado	63	97	+34
Nota	C	A+	—

7. Conclusao

Este artigo documentou a evolucao completa do ecossistema OpenCode ao longo de seis estagios de maturidade, utilizando exclusivamente problemas da IMO como aceleradores de desenvolvimento. As principais contribuicoes sao:

- (1) **Diagnostico de 5 falhas sistematicas** que demonstraram a insuficiencia da verificacao simbolica (V1-V6) para garantir correcao matematica. O caso IMO 2025 P1 foi estabelecido como benchmark canonico para sistemas de verificacao de provas.
- (2) **Taxonomia de 200 raciocinios** em 24 categorias, fundamentada em 150 referencias academicas com DOI/ISBN/arXiv, cobrindo desde logica matematica avancada (Godel [?], Turing [?]) ate socio-antropologia (Difusao [?], Nudge [?]).
- (3) **Arquitetura de verificacao em 4 camadas:** simbolica (V1-V6), estrutural (P20-P23), orquestrada

(38 agentes em 7 fases), e autonoma (busca de elegancia + calibracao 15-D + ciclo de auto-melhoria).

- (4) **Proof Confidence Index (PCI):** metrica unificada 0-100 que integra cross-reference (30%), caso base exaustivo (25%), grafo de lemas (25%), inducao (10%), e consistencia algebrica (10%). Sua trajetoria (85 $\rightarrow$ 30 $\rightarrow$ 88) demonstra que o sistema aprendeu a duvidar de si mesmo antes de produzir respostas corretas.
- (5) **Ciclo de auto-melhoria:** calibracao em 15 dimensoes organizadas em 3 camadas que elevou solucoes de nota C (63/100) para A+ (97/100) em 3 iteracoes automaticas, com ganhos documentados dimensao por dimensao.

A licao mais profunda deste percurso transcende a implementacao tecnica: **a dor de descobrir que se esta errado e o catalisador mais poderoso para a melhoria de sistemas de raciocinio artificial.** A queda do PCI de 85 para 30 — longe de ser uma regressao — foi o momento de maior avanco do ecossistema, pois representou a aquisicao da capacidade de auto-critica.

Problemas de olimpiada, com suas respostas discretas, verificaveis, e independentemente validadas, constituem o banco de provas ideal para calibrar sistemas de raciocinio. Recomenda-se que futuros desenvolvimentos em IA para matematica adotem esta metodologia de *calibracao por falha* como padrao de qualidade.

Referências

[1] OpenCode Ecosystem. *OpenCode Unified Ecosystem v4.2*. 2026.

[2] Cora Architecture. *Arquitetura Hibrida Neural-simbolica para Raciocinio Cientifico Verificavel*. PPGTE/CT/UFC, 2026.

[3] Chen, E. *IMO 2025 Solution Notes*. <https://web.evanchen.cc/exams/IMO-2025-notes.pdf>, 2025.

[4] Google DeepMind. *IMO 2025 Solutions*. https://storage.googleapis.com/deepmind-media/gemini/IMO_2025.pdf, 2025.

[5] IMO. *IMO 2025 Problems*. Bath, UK, 2025.

- [6] IMO. *IMO 2024 Problems and Solutions*. Bath, UK, 2024.
- [7] OpenCode Ecosystem. *CORRIGENDUM v2*. 2026.
- [8] OpenCode Ecosystem. *DOSSIER: Arquitetura de Verificacao Formal (P20-P23)*. 2026.
- [9] OpenCode Ecosystem. *200 Raciocinios em 24 Categorias*. 2026.
- [10] OpenCode Ecosystem. *Autonomous Elegance Engine*. 2026.
- [11] OpenCode Ecosystem. *Advanced Calibration Engine — 15-D*. 2026.
- [12] Auer, P.; Cesa-Bianchi, N.; Fischer, P. Finite-time Analysis of the Multi-armed Bandit Problem. *Machine Learning*, 47(2), 235-256, 2002. DOI: 10.1023/A:1013689704352.
- [13] Platt, J. Probabilistic Outputs for Support Vector Machines. *Advances in Large Margin Classifiers*, 10(3), 61-74, 1999.
- [14] Guo, C.; Pleiss, G.; Sun, Y.; Weinberger, K.Q. On Calibration of Modern Neural Networks. *ICML 2017*. arXiv:1706.04599.
- [15] Meurer, A. et al. SymPy. *PeerJ Computer Science*, 3, e103, 2017. DOI: 10.7717/peerj-cs.103.
- [16] Virtanen, P. et al. SciPy 1.0. *Nature Methods*, 17(3), 261-272, 2020. DOI: 10.1038/s41592-019-0686-2.
- [17] Wang, X. et al. Self-Consistency Improves Chain of Thought Reasoning. *ICLR 2023*. arXiv:2203.11171.
- [18] Liang, T. et al. Multi-Agent Debate. *EMNLP 2024*. arXiv:2305.19118.
- [19] Wei, J. et al. Chain-of-Thought Prompting. *NeurIPS 2022*. arXiv:2201.11903.
- [20] Nash, J.F. Equilibrium Points in n-Person Games. *PNAS*, 36(1), 48-49, 1950.
- [21] von Neumann, J.; Morgenstern, O. *Theory of Games and Economic Behavior*. Princeton, 1944.
- [22] Shapley, L.S. A Value for n-Person Games. *Contributions to the Theory of Games*, II, 307-317, 1953.
- [23] Smith, J.M.; Price, G.R. The Logic of Animal Conflict. *Nature*, 246, 15-18, 1973.
- [24] Macedo, A.M.S. *CORA — Collaborative Reasoning Agents*. PPGF-UFPR, 2025.
- [25] Bellman, R. The Theory of Dynamic Programming. *Bull. AMS*, 60(6), 503-515, 1954.
- [26] Sutton, R.S.; Barto, A.G. *Reinforcement Learning*. MIT Press, 1998.
- [27] Popper, K. *The Logic of Scientific Discovery*. Hutchinson, 1959.
- [28] Kuhn, T.S. *The Structure of Scientific Revolutions*. U. Chicago Press, 1962.
- [29] Polya, G. *How to Solve It*. Princeton, 1945.
- [30] Polya, G. *Mathematics and Plausible Reasoning*. Princeton, 1954.
- [31] Lakatos, I. *Proofs and Refutations*. Cambridge, 1976. DOI: 10.1017/CBO9781139171472.
- [32] Engel, A. *Problem-Solving Strategies*. Springer, 1998. DOI: 10.1007/b97682.
- [33] Zeitz, P. *The Art and Craft of Problem Solving*. 2nd ed. Wiley, 2006.
- [34] Tao, T. *Solving Mathematical Problems*. Oxford, 2006.
- [35] Hardy, G.H. *A Mathematician's Apology*. Cambridge, 1940.
- [36] Burstall, R.M. Proving Properties of Programs by Structural Induction. *The Computer Journal*, 12(1), 41-48, 1969.
- [37] Hoare, C.A.R. An Axiomatic Basis for Computer Programming. *CACM*, 12(10), 576-580, 1969.
- [38] Clarke, E.M.; Grumberg, O.; Peled, D.A. *Model Checking*. MIT Press, 1999.
- [39] Shannon, C.E. A Mathematical Theory of Communication. *Bell System Tech. J.*, 27, 379-423, 1948.
- [40] Turing, A.M. On Computable Numbers. *Proc. London Math. Soc.*, 42, 230-265, 1936.
- [41] Godel, K. Uber formal unentscheidbare Satze. *Monatshefte Math. Phys.*, 38, 173-198, 1931.

- [42] Granovetter, M.S. The Strength of Weak Ties. *Am. J. Sociology*, 78, 1360-1380, 1973.
- [43] Thaler, R.H.; Sunstein, C.R. *Nudge*. Yale, 2008.
- [44] Kalman, R.E. A New Approach to Linear Filtering. *J. Basic Eng.*, 82, 35-45, 1960.
- [45] Kahneman, D.; Tversky, A. Prospect Theory. *Econometrica*, 47(2), 263-292, 1979.
- [46] Axelrod, R. *The Evolution of Cooperation*. Basic Books, 1984.