

# Título do Artigo — Versão Refinada para arXiv

Marcos A. Santos\*, Ana C. Oliveira†

30 de maio de 2026

## Resumo

Este documento serve como template refinado para submissão ao arXiv. Apresenta a estrutura padrão de um artigo científico com seções bem definidas, ambientes matemáticos, tabelas, figuras, algoritmos e referências no formato numérico. O código-fonte está preparado para compilação direta com `pdflatex` e atende aos requisitos do repositório arXiv.

## 1 Introdução

A motivação deste trabalho é demonstrar um template completo e refinado para submissão de artigos ao repositório arXiv [1]. O arXiv aceita submissões em  $\text{\LaTeX}$  desde que o código-fonte seja compatível com as classes padrão (`article`, `amsart`, `revtex4-2`, etc.).

Um aspecto fundamental é a reprodução confiável do documento: todas as fontes, pacotes e imagens devem estar incluídos na submissão. Pacotes não padrão devem ser evitados ou incluídos junto ao código [2].

## 2 Fundamentação Teórica

### 2.1 Formulação Matemática

Seja  $\mathcal{X} \subseteq \mathbb{R}^n$  um espaço de busca e  $f : \mathcal{X} \rightarrow \mathbb{R}$  uma função objetivo. O problema de otimização consiste em encontrar

$$x^* = \arg \min_{x \in \mathcal{X}} f(x) \quad (1)$$

sob um conjunto de restrições  $g_i(x) \leq 0$  para  $i = 1, \dots, m$ .

**Teorema 2.1** (Convergência). *Sob as hipóteses de convexidade de  $f$  e diferenciabilidade com constante de Lipschitz  $L$ , o método do gradiente descendente com taxa de aprendizado  $\eta < 2/L$  converge para o ótimo global:*

$$\|x_{k+1} - x^*\|^2 \leq \left(1 - \frac{2\eta}{L}\right) \|x_k - x^*\|^2 \quad (2)$$

*Demonstração.* A prova segue diretamente da expansão de Taylor de  $f$  em torno de  $x_k$  e da propriedade de Lipschitz do gradiente [3].  $\square$

---

\*Departamento de Computação, Universidade Federal do Ceará. E-mail: marcos.santos@exemplo.com

†Instituto de Ciências Matemáticas, Universidade de São Paulo. E-mail: ana.oliveira@exemplo.com

## 2.2 Análise Estatística

Para um conjunto de  $n$  observações independentes  $\{y_i\}_{i=1}^n$ , o estimador de máxima verossimilhança é dado por

$$\hat{\theta}_{\text{MV}} = \arg \max_{\theta \in \Theta} \sum_{i=1}^n \log p(y_i | \theta) \quad (3)$$

Tabela 1: Métricas de desempenho para diferentes configurações

| Configuração   | Precisão (%)   | Recall (%)     | $F_1$ |
|----------------|----------------|----------------|-------|
| Baseline       | $82.3 \pm 1.2$ | $79.8 \pm 1.5$ | 0.810 |
| Proposta       | $94.7 \pm 0.8$ | $93.1 \pm 0.9$ | 0.939 |
| Estado da arte | $95.2 \pm 0.6$ | $94.5 \pm 0.7$ | 0.948 |

## 3 Metodologia

O pipeline proposto segue três etapas principais, conforme descrito no Algoritmo 1.

---

**Algorithm 1** Pipeline de processamento

---

**Require:** Conjunto de dados  $\mathcal{D}$ , parâmetros  $\Theta$

**Ensure:** Saída processada  $\mathcal{Y}$

- 1:  $\mathcal{X} \leftarrow \text{Pré-processamento}(\mathcal{D})$
  - 2:  $\mathcal{F} \leftarrow \text{Extração de características}(\mathcal{X})$
  - 3: **for** cada amostra  $x_i \in \mathcal{X}$  **do**
  - 4:    $s_i \leftarrow \text{Modelo}(\mathcal{F}_i, \Theta)$
  - 5:   **if**  $s_i > \tau$  **then**
  - 6:      $\mathcal{Y} \leftarrow \mathcal{Y} \cup \{x_i\}$
  - 7:   **end if**
  - 8: **end for**
  - 9: **return**  $\mathcal{Y}$
- 

## 4 Resultados

Os experimentos foram conduzidos em um conjunto de 10 000 amostras com validação cruzada  $k$ -fold ( $k = 5$ ). A Figura 1 ilustra a curva de aprendizado do modelo proposto.

## 5 Discussão

Os resultados indicam uma melhoria significativa em relação ao baseline (Tabela 1), com ganho de 12.4 p.p. na métrica  $F_1$ . A abordagem proposta supera o estado da arte em 2 dos 3 datasets avaliados.

Limitações incluem a dependência do hiperparâmetro  $\tau$  e o custo computacional da etapa de pré-processamento.

[Gráfico: Curva de perda vs. épocas]

Figura 1: Curva de aprendizado do modelo proposto.

## 6 Conclusão

Apresentamos um template refinado para submissão ao arXiv, com estrutura completa de artigo científico. O código está preparado para compilação direta e pode ser adaptado para diferentes áreas do conhecimento.

Trabalhos futuros incluem a extensão para múltiplos datasets e a otimização dos hiperparâmetros de forma automática.

## Agradecimentos

Os autores agradecem ao suporte da CAPES e do CNPq.

## Referências

- [1] arXiv.org. *arXiv Submission Guidelines*, 2024. Disponível em: <https://arxiv.org/help/submit>
- [2] arXiv.org. *Submission FAQ*, 2024. Disponível em: <https://arxiv.org/help/faq/submit>
- [3] S. Boyd and L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004.
- [4] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.